

빅 데이터 분석을 위한 알고리즘

활용 빅 데이터 분석을 위한 알고리즘 소개 및 Python을 활용한 실습



2013.03. – 2015.01. 인하대학교 데이터 마이닝 연구소

- . 최적 용매 물질 분석을 위한 데이터 분석 및 처리 (인하대학교)
- . 지역별 알레르기 환자 특성 비교 프로젝트 (인하대 병원)
- . 수요예측을 위한 최적 시계열 모형 도출 알고리즘 개발 (인하대학교)
- . 한국 공항공사 데이터 분석 (사회 책임 윤리 경영 연구소)
- . 마케팅을 위한 고객 특성에 따른 군집화 알고리즘 생성 (SK Ubcare)

2015.01. – 2017.04. 통계 분석 전문 회사 (Begas)

- . 빅데이터 기반 추계모형 사전 컨설팅 (근로복지공단)
- . 분석 솔루션 개발 (베가스)
- . 제조 공정 질량분석 응용 시스템 개발을 위한 예측 모형 설계 및 개발 (중국 Baosteel)
- . 스마트 팩토리 솔루션 개발 (포스코 ICT)
- . 빅데이터 기반 범죄 분석 프로그램 개발 및 플랫폼 구축 (경찰청)

2017.06. – 2021.02. 인하대학교 고급 통계학 연구소

- . 가슴기살균제 건강피해 인정 및 판정기준 개선연구 (환경 독성 보건학회)

2021.01. – 2022.06. LG CNS


- . 분석 전문가를 위한 교육 프로그램 개발 (LG CNS)
- . 요금제 불만고객탐지 모델 개발 (LG U+)
- . 온라인 행동기반 기업고객 프로파일DB 구축 및 가입상담신청 예측모델개발(LG U+)
- . 영화 콘텐츠 평가 지표 고도화를 위한 지표 및 활용 방안 개발 (LG U+)
- . 불량 분석 솔루션 개발 (LG 에너지 솔루션)

2022.06. – 현재 프리랜서 분석가 & 인하대학교 비전임교원




데이터 분석 사례

범죄 예측을 위한 데이터 분석



< 구역별 위험도 예측 결과 >

< 위험지역 순찰 경로 안내 >




< 군집화 > < 추세 분석 > < 회귀분석 > < 키워드 분석 >

범죄위험도 예측분석 시스템 화면 [자료=경찰청]


* 자료 출처

<http://www.theviewers.co.kr/View.aspx?No=1520602>

넷플릭스 영화 추천 알고리즘 구축



제조업에서의 스마트 팩토리, 스마트 인더스트리



▲ 사진설명: 포스프레임(PosFrame)을 스마트인더스트리로 응용확장하는 과정

* 자료 출처

<https://newsroom.posco.com/kr/포스코-포스프레임posframe으로-스마트인더스트리-주도/>

데이터 분석 사례

영화 콘텐츠 평가지표 개발



인기도

- 영화를 얼마나 많이 시청하였는가
- 영화를 시청한 사람이 얼마나 많은가

몰입도

- 영화를 시청하는데 시청자들이 얼마나 몰입해서 시청하였는가

신선도

- 영화가 서비스된지 얼마가 지났는가
- 영화가 개봉된지 얼마가 지났는가

군집 지표

- 유사한 특성을 가진 영화들에 대한 군집을 생성하여 영화별 군집들에 대한 유사도는 어느 정도인가

통계량 개발

- Exact null distribution for the likelihood ratio test statistic

- LRT statistic

$$LRT = 2 \log \frac{\sup_{H_1} L(b, \tau^2)}{\sup_{H_0} L(b, \tau^2)} \\ = \sup_{\tau \geq 0} \{-\log |V_\lambda| - Y^T P_\lambda^T V_\lambda^{-1} P_\lambda Y + \log |V_{\tau=0}| + Y^T P_{\tau=0}^T V_{\tau=0}^{-1} P_{\tau=0} Y\} \\ V_{\tau=0} \text{ denotes } V_\lambda \text{ under } H_0 \text{ and } P_{\tau=0} = I_n - 1(1^T V_{\tau=0}^{-1} 1)^{-1} 1^T V_{\tau=0}^{-1}$$

- RLRT statistic

$$RLRT = \sup_{\tau \geq 0} \{-\log |V_\lambda| - Y^T P_\lambda^T V_\lambda^{-1} P_\lambda Y - \log |1^T V_\lambda 1| + \log |V_{\tau=0}| + Y^T P_{\tau=0}^T V_{\tau=0}^{-1} P_{\tau=0} Y + \log |1^T V_{\tau=0} 1|\}$$



Let $Z = (Z_1, \dots, Z_n)^T$ where Z_i is generated from $N(0, \sigma_i^2)$.

$$LRT^* = \sup_{\tau \geq 0} \{-\log |V_\lambda| - Z^T P_\lambda^T V_\lambda^{-1} P_\lambda Z + \log |V_{\tau=0}| + Z^T P_{\tau=0}^T V_{\tau=0}^{-1} P_{\tau=0} Z\}$$

Suppose that we generate $LRT_1^*, \dots, LRT_B^*$ for a large B . the p-value is computed as

$$\frac{1}{B} \sum_{j=1}^B (LRT \leq LRT_j^*)$$

의료분야 연구 분석



		Univariate ^a		Multivariate ^a	
		No metabolic diseases (%) ^b	Metabolic diseases (%) ^b	Odds ratio ^c confidence interval ^d	Odds ratio ^c confidence interval ^d
Zepiroline ^e	χ^2	613 (80.4) ^e	149 (19.6) ^e	0.814 ^e	(0.675), 1.2012 ^e
	ϕ^2	0.9785 ^e	1.0345 ^e	1.1099 ^e	1.4176 ^e
Chlorazepate ^e	χ^2	803 (78.9) ^e	217 (21.0) ^e	0.9509 ^e	(0.8177, 1.0986)
	ϕ^2	0.8627 ^e	0.8627 ^e	0.8962 ^e	0.8751 ^e
Olanzapine ^e	χ^2	5670 (79.9) ^e	1429 (20.1) ^e	0.8079 ^e	(0.7666, 0.8962) ^e
	ϕ^2	1.1774 ^e	1.1124 ^e	1.1284 ^e	1.2189 ^e
Quetiapine ^e	χ^2	7604 (75.8) ^e	2422 (24.2) ^e	1.1124 ^e	(0.9535, 1.2846)
	ϕ^2	0.9485 ^e	0.8561 ^e	1.0770 ^e	1.1861 ^e
Aripiprazole ^e	χ^2	2057 (79.5) ^e	530 (20.5) ^e	0.8561 ^e	(0.7750, 0.9436)
	ϕ^2	1.3227 (77.1) ^e	3026 (22.9) ^e	0.9981 ^e	0.9721 ^e
Risperidone ^e	χ^2	13227 (77.1) ^e	3926 (22.9) ^e	0.9981 ^e	0.9721 ^e
	ϕ^2	1.0545 ^e	0.6161 ^e	0.9693 ^e	1.0503 ^e
Aripiprazole ^e	χ^2	4044 (82.5) ^e	850 (17.5) ^e	0.6625 ^e	(0.6161, 0.7129) ^e
	ϕ^2	1.190 (81.2) ^e	718 (18.8) ^e	0.6904 ^e	1.0064 ^e
Paliperidone ^e	χ^2	3190 (81.2) ^e	718 (18.8) ^e	0.7518 ^e	(0.6904, 1.1147) ^e
	ϕ^2	0.8185 ^e			

^a In multivariate analysis, "Number of the types of antipsychotics use" was used as a continuous variable to avoid multicollinearity. ^b Corresponding groups that did not use the respective antipsychotic drug was used as reference.

데이터 분석 프로세스

데이터 분석 프로세스에는 1. 데이터 수집 2. 데이터 탐색 3. 모델링 4. 모형평가 단계로 나뉩니다.

각 단계에서 가장 많은 시간이 소요되는 단계는 "데이터 탐색"으로 단순히 분석 알고리즘을 적용하는 것만큼 매우 중요한 단계입니다.

01



데이터 수집

- 분석에 활용할 데이터 수집 및 추출

02



데이터 탐색

- 데이터 정제(전처리)
- 데이터 시각화
- 데이터 변환

03



모델링

- 분석 알고리즘 적용

04



모형 평가

- 알고리즘 성능 비교
- 알고리즘 성능 평가





TIOBE Index (프로그래밍 언어의 인기를 나타내는 지표)

- 쉽고 간결한 문법을 가진 프로그래밍 언어입니다.
- 활용 분야가 매우 다양합니다. (웹사이트, 데이터 분석, 인공지능, 게임 등)

장점

- 1) 배우기 쉽다: 문법이 간단하여 빠르게 배울 수 있습니다.
- 2) 활용도가 높다: 유튜브, 인스타그램, 넷플릭스 등 우리가 아는 많은 서비스가 파이썬을 사용합니다.
- 3) 강력한 도구가 많다: 복잡한 기능도 미리 만들어진 '라이브러리'를 가져와 쉽게 구현할 수 있습니다.
- 4) 미래가 유망하다: 인공지능(AI), 데이터 과학 분야의 필수 언어로 각광받고 있습니다.

CONTENTS

DATA Analysis

01

파이썬 프로그래밍 기초

파이썬에서 활용 가능한 자료의 형태와 기능들에 대해 학습함

02

데이터 수집

데이터 수집 과정을 소개하고 파이썬을 이용하여 데이터를 수집하는 방법을 학습함

03

데이터 전처리 및 시각화

분석 데이터의 구조 및 형태와 파이썬을 활용하여 분석 데이터를 생성하기 위한 방법들을 학습함

04

AI 알고리즘 맛보기

회귀모형과, Tree기반의 앙상블 모형에 대해 간단히 학습하고 파이썬으로 생성함


05

모형 평가 방법

다양한 AI 알고리즘들을 생성하고 평가하는 방법에 대해 학습함

1.2 코랩(Colab) 사용하기

01. 파이썬 프로그래밍 기초



The image displays two side-by-side screenshots of data science environments. The left screenshot shows the RStudio interface with an R script editor containing code for loading the 'nycflights13' dataset, creating a 'daily' data frame, and plotting the number of flights per weekday. The right screenshot shows the Jupyter Notebook interface with Python code for the same task, including a large Python logo and text about managing the IPython kernel.

RStudio Environment:

```
library(nycflights13) ## package containing flights dataset
library(lubridate)
library(dplyr)
library(ggplot2)

head(flights, n = 3)
daily <- flights %>%
  mutate(date = make_date(year, month, day)) %>%
  count(date) %>%
  mutate(wday = wday(date, label = TRUE))
head(daily, n = 3)
ggplot(daily, aes(wday, n)) +
  geom_boxplot(outlier.colour = "hotpink") +
  labs(x = "Weekday", y = "Flights",
       subtitle = "Number of 2013 New York Flights")
```

Console Output:

```
# A tibble: 3 x 19
  year month day dep_time sched_dep_time dep_delay arr
  <int> <int> <int> <int> <dbl> <int> <dbl> <chr>
1 2013 1 1 517 515 2 830 819 11 UA
2 2013 1 1 533 529 4 850 830 20 UA
3 2013 1 1 542 540 2 923 850 33 AA
```

Jupyter Notebook Environment:

```
# Running Code

First and foremost, the IPython Notebook is an interactive environment for writing and running code. IPython is capable of running code in a wide range of languages. However, this notebook, and the default kernel in IPython 2.0, runs Python code.

## Code cells allow you to enter and run Python code

Run a code cell using 'Shift-Enter' or pressing the button in the toolbar above:

[3]: a = 10

[4]: print(a)
10

There are two other keyboard shortcuts for

• Alt-Enter runs the current cell and
• Ctrl-Enter run the current cell and

Managing the IPython Ke

Code is run in a separate process called the IPython Kernel. The Kernel can be interrupted or restarted. Try running the following cell and then hit the button in the toolbar above.

[ ]: import time
time.sleep(10)


If the Kernel dies you will be prompted to restart it. Here we call the low-level system libc.time routine with the wrong argument via ctypes to segfault the Python interpreter:

[ ]: import sys
from ctypes import CDLL
# This will crash a Linux or Mac system
```


1.2 코랩(Colab) 사용하기

01. 파이썬 프로그래밍 기초

- 구글에서 코랩을 검색하거나 <https://colab.research.google.com>에 직접 접속합니다.
- 새 노트를 클릭합니다.



- 각 셀들을 실행시키고 싶은 경우 셀을 클릭 후, Ctrl+Enter 혹은 Shift+Enter를 누릅니다.




- 코랩 노트북은 두 종류의 셀(Cell)로 이루어져 있습니다.
- 그 중 텍스트 셀에 마크다운(Markdown)이라는 간단한 규칙을 사용하면 깔끔한 문서를 생성할 수 있습니다.

코랩 노트북

■ 코랩 노트북 구조

• **코드 셀:** [] 모양의 아이콘이 왼쪽에 있어요. 이곳에는 파이썬 코드를 작성하고 실행 (▶ 버튼 클릭 또는 Shift+Enter)할 수 있습니다.

텍스트 셀: 이곳에는 지금 글, 이미지, 링크 등을 넣어 설명을 작성할 수 있습니다.



마크다운(Markdown) 실습

■ 마크다운 참고자료링크

- <https://www.markdownguide.org/cheat-sheet/>

■ 마크다운 간단 규칙

- # : 글자 앞에 붙이면 제목을 만들 수 있어요. #이 많을수록 글씨가 작아집니다.
 - # 가장 큰 제목
 - ## 중간 제목
 - ### 작은 제목
- * 또는 - : 문장 앞에 붙이면 목록을 만들 수 있습니다.
 - * 사과
 - * 바나나
- **글자** : 글자를 굵게 만들고 싶을 때 사용합니다.

- 숫자형(Number)이란 숫자 형태로 이루어진 자료형으로, 이미 잘 알고 있는 것들 입니다. 숫자형으로 사용되는 항목에는 정수, 실수, 8진수, 16진수, 복소수 형태가 있습니다.
- 그 중, 정수형과 실수형의 형태가 가장 많이 활용되는 형태라고 할 수 있습니다.

숫자형

■ 숫자형 자료

항목	파이썬 사용 예
정수 (Integer)	123, -345, 0
실수 (Floating-point)	123.45 -1234.5, 3.4e10

- **정수 (Integer):** -3, -2, 0, 1, 5, 100 처럼 소수점이 없는 깔끔한 숫자를 의미합니다.
- **실수 (Float):** 3.14, -2.5, 0.0 처럼 소수점이 있는 숫자예요. ' 둥둥 떠다니는(float) 소수점 ' 을 가졌다고 생각하면 쉽습니다.

파이썬 실습

■ 정수형 / 실수형

▼ 1.1.1. 정수형

```
[1] print(123) # 정수 출력
✓ 0초
▼ 123
```

▼ 1.1.2. 실수형

```
[2] print(123.45) # 실수 출력
✓ 0초
▶ ... 123.45
```

"#" 이란 ?

- 숫자형(Number)을 활용하기 위해 기본적인 사칙 연산 뿐만 아니라 다양한 형태의 연산자를 사용할 수 있습니다.

사칙 연산

```
[1] print(10+5) # 덧셈
     print(10-5) # 뺄셈
     print(10*5) # 곱셈
     print(10/5) # 나눗셈
```

나눗셈 관련

```
[1] print(7/3) # 나눗셈
     print(7//3) # 몫
     print(7%3) # 나머지

2.3333333333333335
2
1
```

- / (그냥 나누기): 우리가 알던 일반적인 나누기예요. 결과를 소수점까지 정확하게 알려줍니다.
- // (몫 구하기): 나눗셈의 정수 몫만 깔끔하게 알려줘요. 소수점 이하는 버립니다.
- % (나머지 구하기): 나눗셈을 하고 남은 나머지만 알려줍니다.

연습 25명의 학생을 4명씩 한 모둠으로 만들려고 할 때, 총 몇 개의 모둠이 만들어지고, 남은 학생은 몇 명인가?

복잡한 계산 (라이브러리 활용 : math)

```
[1] # math 라이브러리(공구함)를 불러옵니다.
     import math
     # math.sqrt() : 제곱근을 구해줍니다.
     print("16의 제곱근:", math.sqrt(16))
     # math.pi : 원주율( $\pi$ ) 값을 알려줍니다.
     print("원주율:", math.pi)
     # math.ceil() : 숫자를 정수로 '올림'해줍니다.
     print("2.1의 올림:", math.ceil(2.1))
     # math.floor() : 숫자를 정수로 '내림'해줘요.
     print("2.9의 내림:", math.floor(2.9))
```

- 문자열(String)이란 문자, 단어 등으로 구성된 문자들의 집합을 의미합니다.
- 문자열의 덧셈과 곱셈 연산으로부터 문자열을 수정할 수 있으며, 문자열 내에 특정 단어나 글자를 선택할 수 있습니다.

문자열 입력 방법

[8] "Hello World"	양쪽에 " 사용
<code>>>> 'Hello World'</code>	
[9] 'Python is fun'	양쪽에 ' 사용
<code>>>> 'Python is fun'</code>	
[10] """Life is too short, You need python"""	양쪽에 """ 사용
<code>>>> 'Life is too short, You need python'</code>	
[11] '''Life is too short, You need python'''	양쪽에 ''' 사용
<code>>>> 'Life is too short, You need python'</code>	

사용 방법 구분

[12] "Python's favorite food is perl"	문장 안에 ' 가 있는 경우
<code>>>> 'Python's favorite food is perl'</code>	
[14] ""Python is very easy." he says."	문장 안에 " 가 있는 경우
<code>>>> ""Python is very easy." he says."</code>	
<code>>>> multiline = ''' Life is too short You need python ''' print(multiline)</code>	여러 줄의 문자열을 생성하는 경우 (원래는 \n 를 사용해야 함)
<code>>>> Life is too short You need python</code>	

문자열 더해서 연결하기 (Concatenation)

```
head = "Python"
tail = " is fun!"
head + tail

'Python is fun!'
```

문자열 곱하기

```
a = "python"
a*2

'pythonpython'
```

문자열 인덱싱 및 슬라이싱

L	i	f	e		i	s		t	o	o		s	h	o	r	t	,		Y	o	u		n	e	e	d		P	y	t	h	o	n
0										1										2										3			
0	1	2	3	4	5	6	7	8	9	0	1	2	3	4	5	6	7	8	9	0	1	2	3	4	5	6	7	8	9	0	1	2	3

```
a = "Life is too short, You need python"
print(a[0])
print(a[-2])

L
o
```

```
print(a[0:4])
print(a[19:])
print(a[19:-7])

Life
You need python
You need
```

- 문자열(String)이란 문자, 단어 등으로 구성된 문자들의 집합을 의미합니다.
- 문자열의 덧셈과 곱셈 연산으로부터 문자열을 수정할 수 있으며, 문자열 내에 특정 단어나 글자를 선택할 수 있습니다.

연습 날짜에서 '월'만 추출하기 ("2026-03-16")

연습 파일 '확장자'만 추출하기 ("파이썬 수업자료.pdf")

연습 주민등록번호에서 '성별'만 추출하기 ("260316-3422345")

문자열 함수 사용 (문자열 메소드)

```
[11]
✓ 0초

# 원하는 문자를 입력하고 실행
text = "Hello, Python!"

print("글자 수:", len(text))
print("대문자로 변환:", text.upper())
print("소문자로 변환:", text.lower())
print("글자 바꾸기:", text.replace("!", "?"))
print("'P'의 위치:", text.find('P'))
print("'z'의 위치:", text.find('z'))
print("공백 제거:", text.replace(" ", ""))
```

글자 수: 14
대문자로 변환: HELLO, PYTHON!
소문자로 변환: hello, python!
글자 바꾸기: Hello, Python?
'P'의 위치: 7
'z'의 위치: -1
공백 제거: Hello,Python!

응용문제 (회원가입 프로그램에서 문자열 함수 활용하기)

코드 셀에 입력하고 실행해보세요!(1/3)

사용자가 작성한 아이디와 비밀번호

```
input_id = " PythonMaster "
```

```
input_pw = " password123 "
```

1. 불필요한 공백 제거

```
cleaned_id = 
```

```
print("공백 제거:", cleaned_id)
```

2. 아이디 길이 제한

아이디가 5글자 이상, 15글자 이하인지 확인합니다.

```
print("아이디 길이:", )
```

3. 아이디를 소문자로 통일하기

'Python'과 'python'을 같은 아이디로 취급하기 위해 모두 소문자로 바꿉니다.

```
final_id = 
```

```
print("최종 아이디:", final_id)
```

4. 비밀번호에 특수문자 '!' 포함 여부 확인

```
print("'!' 포함 여부 (위치):", )
```

[참고] 줄 바꿈과 탭, 특수한 문자들

문자열 안에서 엔터(Enter)를 친 것처럼 줄을 바꾸고 싶은 경우, 이스케이프 문자(Escape Sequence)를 사용합니다.

※ 역 슬래시는 한글 키보드에서 원화표시 ₩ 입니다.

```
[12]
✓ 0초
# \n : 줄 바꿈( New line )
print("첫 번째 줄\n두 번째 줄")
# \t : 탭(Tab) 만큼 공백 넣기
print("이름:\t국성희")
```

첫 번째 줄
두 번째 줄
이름: 국성희

데이터 형 변환(Type Casting)

int() / float() / str()

```
[ ]
print(5 + 5)     # 숫자 5와 5를 더함
print("5" + "5") # 문자 "5"와 "5"를 이어 붙임
```

```
[15]
print(type(10))     # int
print(type(3.14))   # float
print(type('안녕')) # str
```

```
[ ]
num_str = "100"
num_int = int(num_str) # 문자열 "100"을 숫자 100으로 변환
print(num_int + 50)
```

```
[ ]
age = 20
print("제 나이는 " + str(age) + "살 입니다.") # 숫자 20을 문자열 "20"으로 변환하여 문장 연결
```